

Processamento Digital de Imagens: Detecção de Tumor e Segmentação por K-Means

Italo Braga de Paulo
Engenharia da Computação, Universidade de Brasília (UnB)

Resumo—Este trabalho apresenta dois projetos de Processamento Digital de Imagens. O primeiro realiza a detecção automática de um tumor cerebral utilizando filtros de suavização, limiarização Multi-Otsu, operações morfológicas e análise de componentes conexos baseada em características geométricas. O segundo emprega o algoritmo de aprendizado não supervisionado K-Means (Max-Lloyd) para segmentação por cor, utilizando a métrica do Silhouette Score para selecionar automaticamente a melhor quantidade de clusters na imagem.

Index Terms—Processamento Digital de Imagens, Morfologia Matemática, K-Means, Segmentação, Silhouette Score.

I. INTRODUÇÃO

A segmentação é uma das etapas mais importantes do Processamento Digital de Imagens, permitindo isolar regiões de interesse para posterior extração de características e análise computacional. Neste trabalho foram desenvolvidas duas soluções analíticas distintas: uma baseada no processamento espacial e em operações morfológicas para identificação de tumores em imagens cerebrais, e outra baseada em agrupamento (clustering) de dados tridimensionais (RGB) para segmentação por cor em imagens genéricas utilizando o algoritmo K-Means.

II. FUNDAMENTAÇÃO TEÓRICA

A. Detecção por Operações Morfológicas

O primeiro projeto utiliza uma sequência clássica de processamento espacial composta por conversão para tons de cinza, filtragem Gaussiana (passa-baixas) e filtragem não linear da Mediana. A segmentação inicial é feita pela limiarização Multi-Otsu, seguida por operações de abertura e fechamento para refinamento morfológico. A separação final ocorre pela remoção de componentes conectados às bordas e pela seleção da região de interesse com base em métricas de área e *solidity*. Essa sequência garante a redução de ruídos impulsivos e de alta frequência, preservando apenas estruturas anatômicas compatíveis com uma massa tumoral.

B. Algoritmo K-Means

O algoritmo K-Means agrupa amostras em K grupos minimizando a variância intra-cluster, ou seja, a soma das distâncias quadráticas entre cada amostra e o centróide do seu respectivo grupo:

$$J = \sum_{i=1}^K \sum_{x_j \in C_i} \|x_j - \mu_i\|^2 \quad (1)$$

Neste projeto, a imagem é tratada estruturalmente como um conjunto de dados onde cada pixel RGB representa uma amostra tridimensional independente.

C. Silhouette Score

A qualidade da segmentação foi avaliada analiticamente através do Silhouette Score:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (2)$$

Esta métrica pondera a distância intra-cluster ($a(i)$) com a distância para o cluster vizinho mais próximo ($b(i)$). Valores próximos de 1 indicam agrupamentos altamente coesos e bem separados, refletindo uma melhor qualidade geométrica na segmentação.

III. METODOLOGIA

A. Projeto 1 – Detecção de Tumor

Inicialmente, a imagem de entrada foi validada e convertida para escala de cinza, garantindo a manipulação em um único canal de intensidade. Em seguida, aplicou-se um filtro Gaussiano com desvio padrão $\sigma = 1$ para uma suavização global, atenuando altas frequências. Para a remoção de ruídos impulsivos sem a degradação excessiva das bordas orgânicas, aplicou-se um filtro da Mediana configurado com um elemento estruturante em formato de disco de raio 3.

A binarização da imagem processada foi conduzida utilizando o método limiarização por Multi-Otsu otimizado para três classes distintas de intensidade. Extraíndo-se o segundo limiar gerado pelo algoritmo, foi possível isolar com precisão apenas a classe mais brilhante da imagem, que correspondia fundamentalmente à massa tumoral e à calota craniana.

Para refinar a máscara obtida, aplicaram-se operações morfológicas utilizando um elemento estruturante em formato de disco (raio 3). Executou-se a operação de abertura, removendo pequenos artefatos periféricos, seguida do fechamento, responsável por preencher pequenos vazios no interior da região binarizada. Visando a eliminação primária do crânio, utilizou-se a operação *clear_border*, que suprime instantaneamente quaisquer componentes que toquem as extremidades da imagem.

A distinção final entre o tumor e fragmentos remanescentes do crânio foi feita através da rotulação (*label*) e análise geométrica de componentes conexos (*regionprops*). Filtrou-se o resultado para componentes com área superior a 50 pixels e

solidity maior que 0.6. A *solidity* (razão entre a área do componente e a área de seu polígono convexo) garantiu a seleção do tumor (massa altamente densa) em detrimento de fragmentos cranianos (estruturas curvas e alongadas). O componente de maior área restante foi delimitado e seu respectivo contorno foi plotado sobre a imagem original em tons de vermelho.




Figura 1. Resultado da detecção automática do tumor após o processo morfológico e isolamento por densidade geométrica.

B. Projeto 2 – Segmentação por K-Means

A imagem base foi lida estruturalmente como um array e reformulada para uma matriz bidimensional, transformando os dados espaciais em uma lista linear onde cada entrada representava um pixel em suas três dimensões de cor (RGB). Para determinar o número ótimo de regiões na imagem, o algoritmo K-Means, instanciado da biblioteca *Scikit-Learn*, iterou sobre os valores de K entre 2 e 10. A estabilidade convergencial foi assegurada realizando 10 inicializações randômicas distintas ($n_init=10$) sob uma semente controlada ($random_state=42$).

A validação de cada valor de K foi submetida ao cálculo do *Silhouette Score*. Para viabilizar a análise sob um custo computacional adequado, a métrica foi computada sobre uma subamostra representativa de 5000 pixels. A partir do agrupamento, o algoritmo reconstruiu a imagem original associando, a cada pixel original, a cor média correspondente ao centróide de seu cluster. Esses valores numéricos foram subsequentemente convertidos para inteiros de 8 bits sem sinal (*uint8*) para viabilizar a renderização visual da nova imagem.

O sistema localizou dinamicamente o índice correspondente ao maior *Silhouette Score* no vetor de resultados para definir automaticamente o valor ótimo do parâmetro K .

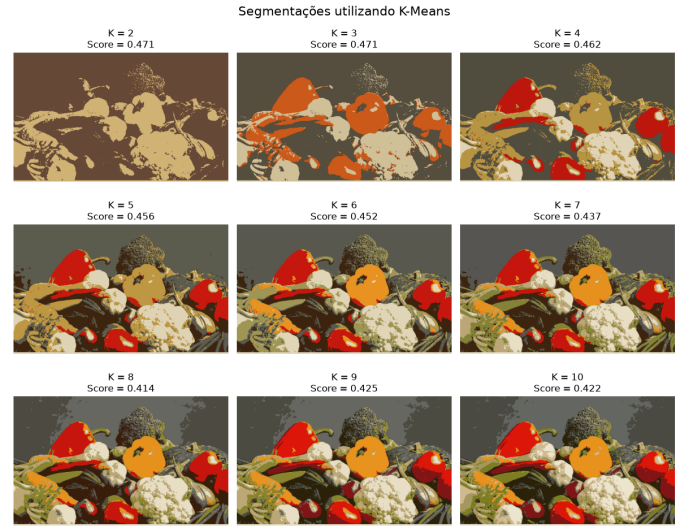


Figura 2. Segmentações independentes obtidas durante as iterações para os diferentes valores de K testados.




Figura 3. Curva de convergência do Silhouette Score indicando o pico de coesão visual.



Figura 4. Comparação direta evidenciando a reconstrução cromática da imagem por meio da média dos centróides selecionados.

IV. RESULTADOS E DISCUSSÃO

No primeiro projeto, constatou-se que a configuração encaixada de filtros passa-baixa foi eficiente na homogeneização dos tecidos moles. A limiarização Multi-Otsu, dividida em três classes, simplificou eficientemente a distinção orgânica. O principal diferencial observou-se no uso da métrica de *solidity*, que demonstrou alta capacidade de rechaçar os remanescentes

da calota craniana que sobreviveram à função de borda, conferindo grande robustez preditiva à rotina de detecção automática do tumor.

Quanto ao segundo projeto, os testes demonstraram que a técnica de clusterização tridimensional RGB resultou em aglomerações coerentes no que tange aos aspectos de matiz e intensidade dos pixels. A plotagem da curva do *Silhouette Score* apontou, de forma não ambígua, o valor ideal correspondente a $K = 3$ como o melhor balanceamento matemático da imagem analisada. Verificou-se que a imposição de um K maior força o algoritmo a sub-segmentar regiões naturais, pulverizando os clusters e deteriorando rapidamente o score em conformidade com as penalidades da métrica de coesão intra-grupo.

V. CONCLUSÃO

Os desenvolvimentos apresentados atestam a flexibilidade de abordagens clássicas em Processamento Digital de Imagens, aplicáveis a domínios que vão do escopo biomédico ao de inteligência computacional por cores. A arquitetura implementada no primeiro caso reitera a necessidade do ajuste sensível de parâmetros morfológicos e extração de características em operações de precisão. O segundo experimento comprova que parâmetros não supervisionados podem ser regulados confiavelmente através de métricas de otimização intrínsecas, eximindo o observador humano da tarefa de calibração exata.

Do ponto de vista da clusterização de cores, cabe ressaltar que embora a técnica de K-Means aplicada ao espaço de cores padrão (RGB) cumpra satisfatoriamente os objetivos delineados no escopo deste trabalho, existe margem metodológica para aprimoramento. Uma alternativa comum e altamente encorajada no Processamento Digital de Imagens é a conversão da imagem original para o espaço de cor Lab (CIELAB) antes de se instanciar o cálculo pelo K-Means. Nesse espaço colorimétrico não-linear, as distâncias euclidianas aproximam-se muito mais da maneira como a visão e a percepção humana quantificam as diferenças entre as cores, resultando frequentemente em segmentações com fronteiras mais naturais e consistentes frente à variação de iluminação na cena. Uma análise comparativa dos resultados obtidos nos espaços RGB e Lab pode, portanto, configurar um valioso aprofundamento para trabalhos futuros.

REFERÊNCIAS

- [1] R. C. Gonzalez e R. E. Woods, *Processamento Digital de Imagens*, 3ª ed., Pearson, 2010.
- [2] Scikit-Learn Developers, *Scikit-Learn Documentation*.
- [3] Scikit-Image Developers, *Scikit-Image Documentation*.